

DutchSemCor - Corpora and the FoLiA format

Maarten van Gompel
Tilburg University
Radboud University Nijmegen

25 October 2012



1 Introduction

- Corpora

2 SoNaR

- Objective & Partners
- Characteristics
- Contents
- SoNaR in DutchSemCor

3 Web-snippets

- Snippet Tool

4 FoLiA

- Introduction
- Motivation & Dissemination
- Uniform Paradigm
- Attributes
- FoLiA for DutchSemCor
- Tools
- Delivery
- Extra: FoLiA paradigm scheme

Corpora

DutchSemCor builds on three sources of corpus data:

- **SoNaR** corpus: The biggest Dutch language corpus, covering over 500 million words (67% of the manual annotations)
- Corpus Gesproken Nederlands (5% of the manual annotations)
- Custom **web-snippets**: selected fragments from the internet for uncommon senses (28% of the manual annotations)

..and annotates occurrences of the 3000 word-types as **Cornetto** lexical units.

SoNaR

SoNaR

The SoNaR Corpus

- 500 million word reference corpus
- contemporary standard written Dutch
- texts from The Netherlands and Flanders

Partners

Part of the STEVIN programme

Netherlands: Radboud University Nijmegen, Tilburg University, Twente University & Utrecht University

Belgium (Flanders): University College Ghent, KU Leuven

SoNaR Characteristics (1)

- includes native speaker language and the language of (professional) translators
- approx. two-thirds of the data originates from the Netherlands and one-third from Flanders
- only texts included from the year 1954 onwards, in practice: only digitally-born texts
- comprises full texts rather than text samples
- includes texts from a wide range of 40 text types
- for (almost) all data IPR has been arranged

SoNaR Characteristics (2)

- Tokenised
- Part-of-speech tagged
- Lemmatised
- Named Entities
- Delivered in FoLiA XML. Pre-releases only in D-Coi XML

SoNaR Contents

- 40 text types
- old and new media
- all contemporary, written Dutch

SoNaR Contents

- Books
- Newspapers
- Theses
- Magazines
- SMS
- Tweets
- Forums
- Chat logs

Working with SoNaR to build DutchSemCor

Objective: Real-time Keyword-in-Context search for Annotation Tool

Challenge: Tremendous amount of data, over two million XML files

Solution: Convert corpus into relational database optimised for KWIC-queries from the Semantic Annotation Tool

Web-Snippets

Web-Snippets

Web-snippets

Problem: SoNaR may not be sufficient to find enough different samples (25) for certain less common senses

Solution: Let annotators search for suitable fragments on the internet using the Snippet tool.

Snippet Tool

- 1 Annotators enter a query word and optional co-occurrence filter
- 2 The system issues a query to webcorp.co.uk and presents results
- 3 The annotator makes a selection of desired fragments from the results
- 4 Fragments are tokenised, PoS-tagged, lemmatised and added to the underlying database, making them available in the SAT

[\(Log out dutchsemcor | Beheer](#)

DutchSemCor Snippet Processing & Extraction Tool

 Zoekwoord:

 Filter:

Voeg extra woorden toe die op dezelfde pagina als de zoekterm moeten verschijnen (of juist niet, gebruik daarvoor het minteken (-)). Bijvoorbeeld voor het zoekwoord 'bank' kan je 'zitten' meegeven om de resultaten te sturen richting een gewenste betekenis.

 Aantal binnen te halen pagina's:

 Databron:

 Lemma

Voer het exacte lemma in waar je naar zoekt. Deze data wordt niet gebruikt voor het zoeken zelf, maar dit lemma zal aan **alle** gekozen woorden toegewezen worden. Laat dit veld leeg om het automatisch te detecteren (wetende dat het systeem er soms naast kan zitten).

 Part-of-Speech tag

Enter the exact PoS-tag belonging to the lemma specified above, this data will not be used for querying, but to assign the right pos-tag to the words you find.

(Het kan een tijdje duren voor je zoekopdracht verwerkt is!)

SnipPET: Snippet Processing and Extraction Tool
voor DutchSemCor
door Maarten van Gompel, Universiteit van Tilburg

2


[\(Log out dutchsemcor | Beheer \)](#)

DutchSemCor Snippet Processing & Extraction Tool

1	Deze Laphrios zou het	beeld	van goud en ivoor hebben besteld bij de beeldhouwers Menaichmos en Soidas in Calydon.
2	Zij lieten Damophon van Messene nog een chryselephantine	beeld	van Artemis Laphria maken in de 2e eeuw v.
3	In de tempel bevond zich een	beeld	van de godin in goud en ivoor, vermomd als jaagster.
4	Damophon van Messene maakte onder andere nog een chryselephantine	beeld	van Artemis Laphria in de 2e eeuw v.
5	[2] Bij de verwoesting van Aetolië door keizer Augustus werd het	beeld	door de inwoners van Patrai in de kleine tempel van Artemis in Patrai in veiligheid gebracht.
6	De bijnaam van de godin is van vreemde oorsprong, en ook haar	beeld	werd van elders hierheen gebracht.
7	Voor christenen was en is, tot op de dag van vandaag, het	beeld	een mysterium en zij beschouwen het als een drager van Goddelijke energie en genade.
8	Gij zult u geen gesneden	beeld	maken noch enige gestalte [.
9	Inhoud 1 Geschiedenis 2 Het	beeld	2.
10	[bewerken] Het	beeld	[bewerken] Ontwerp De Academy Award bestaat uit een gouden beeld van 35,1 centimeter hoog.
11	[bewerken] Het beeld [bewerken] Ontwerp De Academy Award bestaat uit een gouden	beeld	van 35,1 centimeter hoog.

FoLiA: Format for Linguistic Annotation

FoLiA: Format for Linguistic Annotation



What is FoLiA?

- Generalised XML-based format for a wide variety of linguistic annotation

FoLiA Characteristics

- **Uniform** setup – Consistent and uniform paradigm unifying various kinds of annotation. Not committed to any label set.
- **Extensible & Flexible** – Easy to extend
- **Expressive** – Verbose expression of annotations, their annotators, timestamps, etc... Moreover, support for *alternative* annotations.
- **Formalised** – Validation on shallow (structural) or deep level. The latter validates the label set and allows for links with for data category registries (e.g. ISOcat).
- **Practical** – Bottom-up development alongside libraries, various applications, different projects.

Intended Applications

- as a corpus **storage** format
- as a language resource **exchange** format

Properties

- One document, one text, one XML file – containing all annotations.
- Annotation types and label sets must be declared in the document header
- Document metadata by reference to external CMDI files (amongst other options)

Why (yet) another format?

- Many ad-hoc and legacy annotation formats (CGN, Tadpole column format)
- Many theoretic and specialised annotation formats with limited scope (LAF, SynAF, MAF, TEI)
- Bottom-up rather than top-down development: FoLiA arose from practical need, immediately developed alongside practical programming libraries and applications.
- De-facto-standard: D-COI XML: now being replaced by FoLiA

Dissemination


- **DutchSemCor**
- SoNaR
- TTNWW, Ticclops, VU-DNC (CLARIN)
- Valkuil.net, fowlt.net
- Leesbaarheidsindex Nederlands (LIN) (NWO)
- Basilex (NWO)
- Frog & Ucto

Uniform Paradigm: Annotation Categories

Categories of annotation:

- **Structure Annotation** - Elements denoting document structure
 - E.g: Divisions, Header, Paragraphs, Sentences, Lists, Figures, Gaps, Quote
- **Token Annotation** - Linguistic Annotations pertaining to a single token (inline annotation)
 - E.g: Part of Speech Annotation, Lemma Annotation, **Lexical Semantic Sense Annotation**
- **Span Annotation** - Linguistic Annotations spanning over multiple tokens (standoff annotation)
 - E.g: Syntactic Parses, Dependency Relations, Entities/Multi-word Units

- uniform paradigm -



FoLiA for DutchSemCor

Lexical semantic sense annotation using the sense element, well integrated in the FoLiA paradigm.

```
<w xml:id=" example.p.1.s.1.w.2">
  <t>beeld</t>
  <pos class="N(soort, ev, basis, onz, stan)" />
  <lemma class=" beeld" />
  <sense class=" r_n-6220" />
</w>
```

Tools for working with FoLiA

- Standard **XML** facilities: XSLT, XPath
- **Python** library: `pynlpl.formats.folia`
- **C++** library: `libfolia` (*Ko van der Sloot*)

Applications

- **Frog** – tagger/lemmatisation/parser suite
- **ucto** – tokeniser

FoLiA Website

Documentation, validation schemas, tools (incl. converters):
<http://proycon.github.com/folia>

DutchSemCor Delivery

- Superset of SoNaR corpus in FoLiA XML, enriched with over 144 million sense tags (from Cornetto).
- .. of which 350,000 manually annotated sense tags.

Fin



Extra: FoLiA paradigm scheme

